

Universidad Nacional Mayor de San Marcos
Universidad del Perú. Decana de América
Facultad de Ingeniería de Sistemas e Informática
Unidad de Posgrado



**Gestión de información documental para la recomendación
auditable de subpartidas NANDINA mediante recuperación
documental y LLM+RAG: piloto experimental offline**

PROYECTO DE INVESTIGACIÓN

Autor:

Vladimir Molleapasa Gutiérrez

Lima, Perú

2026

ÍNDICE

I. PLANTEAMIENTO DEL PROBLEMA	4
1.1. Situación problemática	4
1.2. Formulación del problema	6
1.2.1. Problema general	6
1.2.2. Problemas específicos	6
1.3. Justificación de la investigación	7
1.3.1. Justificación teórica	7
1.3.2. Justificación práctica	8
1.3.3. Justificación metodológica	9
1.4. Objetivos de la investigación	9
1.4.1. Objetivo general	9
1.4.2. Objetivos específicos	10
1.5. Alcance de la investigación	10
II. MARCO TEÓRICO	12
2.1. Antecedentes del problema	12
2.1.1. Clasificación arancelaria asistida por aprendizaje automático	12
2.1.2. Recuperación semántica para códigos HS	14
2.1.3. Explicabilidad en clasificación aduanera	16
2.1.4. Documentación de datos/conocimiento	18
2.2. Bases teóricas	19
2.2.1. Gestión del conocimiento e información	19
2.2.2. Conocimiento normativo arancelario y Sistema Armonizado	20
2.2.3. Recuperación de información para apoyo a decisiones	21
2.2.4. Modelos de lenguaje, RAG y explicación basada en evidencia	22
2.2.5. Documentación de datos, trazabilidad y reproducibilidad	22

2.3. Marco conceptual o glosario	23
III. HIPÓTESIS Y VARIABLES	26
3.1. Hipótesis general	26
3.2. Hipótesis específicas	26
3.3. Identificación de variables	27
3.4. Operacionalización de variables	27
3.5. Matriz de consistencia	29
IV. METODOLOGÍA	31
4.1. Tipo y diseño de investigación	31
4.2. Unidad de análisis	32
4.3. Población de estudio	33
4.4. Tamaño de muestra	33
4.5. Selección de muestra	34
4.6. Técnicas de recolección de datos	34
4.7. Análisis e interpretación de la información	35
V. PRESUPUESTO	37
VI. CRONOGRAMA DE ACTIVIDADES	38
VII. REFERENCIAS BIBLIOGRÁFICAS	39
VIII. ANEXOS	43
Anexo 1. Estructura preliminar de salida del piloto	43
Anexo 2. Rúbrica preliminar de calidad de explicación auditable	44
Anexo 3. Alcances y límites preliminares	45

I. PLANTEAMIENTO DEL PROBLEMA

1.1. Situación problemática

La clasificación arancelaria es una actividad intensiva en conocimiento normativo, técnico y documental. La determinación de una subpartida no se limita a asociar una descripción comercial con una etiqueta numérica; implica interpretar una nomenclatura jerárquica, aplicar reglas generales, revisar notas legales y sostener una decisión ante posibles instancias de control. En el comercio internacional, el código asignado incide en tributos, restricciones, estadísticas, autorizaciones y cumplimiento normativo. Por ello, la clasificación errónea genera riesgos económicos, administrativos y de trazabilidad institucional.

La literatura reciente confirma que la clasificación basada en el Sistema Armonizado (*Harmonized System, HS*) presenta dificultades incluso para especialistas. Grainger (2024) sostiene que los problemas se explican por la complejidad de la nomenclatura, la interpretación de reglas y la necesidad de reconocer características relevantes de las mercancías. En la misma línea, Lee et al. (2024) comparan el proceso con una tarea de decisión experta, en la cual los oficiales revisan descripciones, antecedentes y manuales técnicos antes de formular una clasificación sustentada. Esta situación muestra que la clasificación arancelaria no es solo un problema de automatización, sino un problema de organización, recuperación, uso y validación de conocimiento especializado.

En contextos operativos, las descripciones de mercancías suelen ser breves, incompletas, heterogéneas o redactadas con vocabulario comercial que no coincide con el lenguaje formal de la nomenclatura. Luppés (2019) describe que las descripciones cortas generan escasez de rasgos textuales, contienen abreviaturas o errores y se distribuyen entre miles de posibles clases. Spichakova y Haav (2020) añaden que la brecha semántica entre la descripción comercial y la descripción legal del HS reduce la eficacia de búsquedas literales y obliga a incorporar mecanismos de

similitud semántica y conocimiento taxonómico. Desde una perspectiva de gestión de información, el problema central consiste en transformar documentos normativos y descripciones operativas dispersas en recursos estructurados, consultables y evaluables.

El presente estudio propone diseñar y evaluar un piloto experimental offline de gestión de información documental normativa, orientado a organizar, recuperar, reordenar y explicar evidencia documental para apoyar la recomendación auditable de subpartidas NANDINA. Para ello, se implementará un pipeline que combinará recuperación documental y modelos de lenguaje de gran tamaño con generación aumentada por recuperación. Este encuadre sitúa la investigación en el campo de la gestión del conocimiento e información, en lugar de reducirla a una tarea de automatización clasificatoria.

La gestión del conocimiento aporta el marco conceptual para comprender esta transformación. Alavi y Leidner (2001) señalan que los sistemas de gestión del conocimiento deben facilitar, entre otros procesos, la creación, almacenamiento, recuperación, transferencia y aplicación del conocimiento organizacional. Nonaka (1994) enfatiza la relación entre conocimiento tácito y explícito: la experiencia del especialista requiere ser externalizada, estructurada y reutilizada. En el dominio arancelario, esta relación se observa con claridad: parte del conocimiento reside en documentos formales, mientras otra parte se expresa en criterios interpretativos, experiencia acumulada y patrones de decisión. Un enfoque experimental basado en recuperación documental y explicación auditable permite aproximar ambos planos, sin sustituir la decisión experta.

El problema de investigación se formula, por tanto, en la intersección de tres dimensiones. La primera es informacional: cómo curar, estructurar y versionar un corpus normativo NANDINA, reglas generales, notas legales y evidencia complementaria. La segunda es tecnológica: cómo recuperar y reordenar candidatos relevantes a partir de descripciones textuales de mercancías. La tercera es de gobernanza del conocimiento: cómo producir explicaciones trazables, verificables y útiles para auditoría. La investigación no pretende desplegar un sistema productivo ni

reemplazar al especialista; busca evaluar, en condiciones offline y reproducibles, si un enfoque experimental de gestión de información documental mejora la recomendación y el sustento documental de subpartidas NANDINA.

1.2. Formulación del problema

1.2.1. Problema general

¿En qué medida un piloto experimental offline de gestión de información documental, implementado mediante recuperación documental y LLM+RAG, mejora la recomendación auditable de subpartidas NANDINA a partir de descripciones textuales de mercancías, en términos de desempeño Top-k/ranking y calidad de explicación basada en evidencia?

1.2.2. Problemas específicos

- PE1.** ¿Qué enfoques reporta la literatura para la clasificación, recomendación y verificación de códigos HS a partir de descripciones textuales, y qué aportes ofrecen para la gestión de información documental normativa en clasificación arancelaria?
- PE2.** ¿Cómo debe estructurarse un corpus documental de conocimiento NANDINA para soportar recuperación, trazabilidad, versionamiento y explicación auditable?
- PE3.** ¿En qué medida la etapa de recuperación base logra incluir la subpartida correcta dentro de los candidatos Top-N y ordenar candidatos relevantes a partir de descripciones textuales?
- PE4.** ¿En qué medida el componente LLM+RAG mejora el reordenamiento de candidatos y la recomendación final Top-k frente a la recuperación base?

- PE5.** ¿En qué medida las explicaciones generadas alcanzan calidad aceptable de auditabilidad, verificabilidad, trazabilidad de evidencia y concordancia evidencia-justificación?
- PE6.** ¿Qué patrones de error, confusión jerárquica y dependencia de la calidad descriptiva se observan en el piloto experimental, y qué implicancias tienen para la gestión de información documental normativa en clasificación arancelaria?

1.3. Justificación de la investigación

1.3.1. Justificación teórica

La investigación se justifica teóricamente porque articula el campo de la gestión del conocimiento con un problema aplicado de clasificación arancelaria. En lugar de abordar la recomendación de subpartidas solo como una tarea de aprendizaje automático, el estudio la interpreta como un proceso de codificación, recuperación y aplicación de conocimiento explícito. Esta perspectiva permite observar el corpus NANDINA y los documentos normativos como activos de conocimiento que requieren curación, metadatos, control de versiones, reglas de acceso y mecanismos de validación.

El aporte conceptual consiste en integrar tres líneas teóricas: gestión del conocimiento organizacional, recuperación de información y explicabilidad para sistemas de apoyo a decisiones. Alavi y Leidner (2001) proveen una base para entender los sistemas de gestión del conocimiento como infraestructura para almacenar, recuperar y aplicar conocimiento. Bender y Friedman (2018) y Gebru et al. (2021) permiten reforzar la documentación de datos, procedencia, sesgos y límites de uso. Karpukhin et al. (2020), Khattab y Zaharia (2020), y Lewis et al. (2020) respaldan el componente de recuperación y generación aumentada por recuperación. En conjunto, estas fuentes permiten construir un marco para estudiar cómo la

evidencia documental puede ser transformada en soporte verificable para una recomendación arancelaria.

1.3.2. Justificación práctica

Desde la perspectiva práctica, el estudio aborda una necesidad frecuente en procesos aduaneros y de comercio exterior: reducir la carga de búsqueda manual y mejorar la trazabilidad del criterio utilizado para sustentar una clasificación. La literatura sobre clasificación HS muestra que los errores pueden originarse en descripciones insuficientes, ambigüedad terminológica, clases desbalanceadas y dificultad para distinguir categorías próximas (Ding et al., 2015; Grainger, 2024; Luppés, 2019). Un piloto experimental offline permite estudiar estas dificultades sin comprometer operaciones reales ni asumir que la salida del modelo tenga valor decisorio automático.

La utilidad esperada se concentra en tres productos: un corpus documental curado y documentado, un protocolo experimental reproducible y una evaluación cuantitativa-cualitativa del desempeño y de la explicación. Estos productos pueden servir como base para investigaciones posteriores, para discusiones institucionales sobre sistemas de apoyo a la clasificación y para el diseño de mecanismos de control documental en sistemas RAG (*Retrieval-Augmented Generation*) aplicados a dominios normativos.

Este enfoque se alinea con los criterios de gobernanza de sistemas de IA propuestos por el *National Institute of Standards and Technology* (NIST, 2023), que establece la explicabilidad, la trazabilidad de procedencia y la responsabilidad documental como características centrales de sistemas de IA confiables en contextos de toma de decisiones.

1.3.3. Justificación metodológica

Metodológicamente, el estudio se justifica porque propone evaluar un *pipeline* completo, no únicamente un clasificador. La literatura muestra que los enfoques de similitud semántica, aprendizaje supervisado y recuperación de evidencia ofrecen resultados prometedores, pero también presentan limitaciones de datos, generalización y explicabilidad (Anggoro et al., 2025; Lee et al., 2024; Marra de Artiñano et al., 2023).

Stassin et al. (2023) muestran que los modelos de similitud semántica superan a los supervisados en precisión Top-k para predicción de códigos HS de alta granularidad, lo que refuerza la pertinencia de evaluar enfoques de recuperación semántica como componente del pipeline propuesto.

Por ello, se plantea una evaluación por componentes: recuperación base, reordenamiento LLM+RAG, recomendación final y calidad de la explicación. Esta separación permite identificar en qué parte del proceso se gana o pierde valor informacional.

1.4. Objetivos de la investigación

1.4.1. Objetivo general

Evaluar, mediante un piloto experimental offline, un enfoque de gestión de información documental para la recomendación auditable de subpartidas NANDINA a partir de descripciones textuales de mercancías, implementado mediante recuperación documental y LLM+RAG, midiendo su desempeño Top-k/ranking y la calidad de las explicaciones basadas en evidencia.

1.4.2. Objetivos específicos

- OE1.** Sistematizar los enfoques reportados por la literatura para clasificación, recomendación y verificación de códigos HS a partir de texto, identificando su aporte a la gestión de información documental normativa y a la explicación auditable.
- OE2.** Construir o consolidar un corpus documental de referencia para NANDINA y documentos normativos relacionados, incorporando criterios de curación, trazabilidad, metadatos y versionamiento.
- OE3.** Implementar y evaluar una etapa de recuperación base para generar candidatos Top-N a partir de descripciones textuales, documentando parámetros, granularidad documental, preprocesamiento y recursos de ejecución.
- OE4.** Diseñar e implementar un componente LLM+RAG para reordenar candidatos y producir una salida estructurada con subpartida recomendada, puntaje, fragmentos citados y justificación auditable.
- OE5.** Evaluar el desempeño del pipeline completo mediante métricas Top-k, *Mean Reciprocal Rank (MRR)* y *Normalized Discounted Cumulative Gain (nDCG)*, bajo un protocolo offline reproducible.
- OE6.** Definir y aplicar indicadores de calidad de explicación para auditoría, considerando verificabilidad, trazabilidad de evidencia, pertinencia documental y concordancia evidencia-justificación.
- OE7.** Analizar cuantitativa y cualitativamente los errores del piloto, incluyendo confusiones por nivel jerárquico, sensibilidad a configuraciones de recuperación y patrones asociados a la calidad de la descripción.

1.5. Alcance de la investigación

El alcance del proyecto será experimental y offline. El estudio no realizará clasificación oficial de mercancías, no sustituirá la revisión experta y no se

implementará en un entorno operativo. La unidad de evaluación será cada caso textual procesado por el piloto y contrastado contra una etiqueta de referencia. El aporte esperado será metodológico y empírico: un enfoque experimental de gestión de información documental aplicado a un corpus normativo, un protocolo de recuperación y explicación auditable, y evidencia sobre su desempeño y sus límites bajo condiciones controladas.

La investigación se concentrará en subpartidas NANDINA de ocho dígitos. Las referencias a HS y HTS se emplearán únicamente como antecedentes conceptuales y comparativos; no se evaluarán códigos nacionales adicionales, tributos efectivos, restricciones administrativas específicas ni decisiones institucionales vinculantes.

II. MARCO TEÓRICO

2.1. Antecedentes del problema

Los antecedentes se organizan en cuatro grupos: clasificación arancelaria asistida por aprendizaje automático, recuperación semántica para códigos HS, explicabilidad en clasificación aduanera y documentación de datos/conocimiento. Esta organización responde al enfoque de la investigación, en tanto el problema no se limita a la precisión predictiva, sino que incorpora la forma en que el conocimiento normativo se estructura, se recupera y se convierte en evidencia revisable para apoyar decisiones en un dominio regulado.

2.1.1. Clasificación arancelaria asistida por aprendizaje automático

La clasificación arancelaria asistida por aprendizaje automático ha sido abordada como una tarea compleja de clasificación textual, caracterizada por descripciones breves, heterogéneas, con vocabulario comercial variable y con un elevado número de clases posibles. En esta línea, Ding et al. (2015) propusieron un sistema de autocategorización de códigos HS mediante el enfoque *Background Net*, orientado a representar asociaciones semánticas entre productos y códigos arancelarios. Su estudio muestra que la clasificación basada en el Sistema Armonizado requiere modelar relaciones de significado más allá de la coincidencia literal de palabras, debido a la diversidad terminológica de las descripciones comerciales y a la complejidad de la nomenclatura.

Luppés (2019) evaluó redes neuronales convolucionales para clasificar textos cortos del Sistema Armonizado. El estudio documentó dificultades propias del

dominio, como la brevedad de las descripciones, la presencia de errores, abreviaturas, escasez de rasgos textuales y alta cardinalidad de clases. Estos elementos permiten comprender la clasificación HS como un problema de procesamiento de lenguaje especializado, donde las descripciones de mercancías no siempre contienen información suficiente ni se ajustan al vocabulario formal de la nomenclatura.

Anggoro et al. (2025) desarrollaron un enfoque de clasificación HS basado en *Sentence-BERT* y aprendizaje contrastivo supervisado mediante *Multiple Negative Ranking Loss*. Su propuesta incorpora representaciones semánticas de transacciones comerciales para mejorar la discriminación entre clases próximas. Este antecedente se ubica dentro de una evolución metodológica que desplaza la clasificación desde modelos puramente léxicos hacia representaciones densas capaces de capturar similitudes semánticas entre descripciones de mercancías y códigos arancelarios.

Liao et al. (2024) propusieron un modelo *ERNIE-BiLSTM* con mecanismos de atención multiescala para la clasificación de códigos HS en mercancías de importación y exportación. El estudio parte de la premisa de que las declaraciones comerciales contienen textos semiestructurados, vocabulario profesional y atributos de mercancía distribuidos de forma irregular. La incorporación de atención multiescala permite identificar rasgos relevantes en distintos niveles de representación textual, lo cual resulta consistente con la necesidad de procesar descripciones comerciales que no siguen una estructura uniforme.

Cuaya-Simbro et al. (2022) desarrollaron un sistema de clasificación arancelaria mediante aprendizaje profundo aplicado a imágenes de café. Aunque el enfoque se basa en información visual y no textual, el trabajo evidencia que la clasificación arancelaria puede depender de atributos técnicos de la mercancía y que los sistemas computacionales pueden apoyar la identificación de fracciones arancelarias cuando estos atributos son representados de forma adecuada. Este antecedente amplía la comprensión del problema al mostrar que la clasificación arancelaria asistida puede apoyarse en distintas modalidades de información, siempre que estas permitan reconocer características relevantes para la nomenclatura.

Krupa y Kunanets (2024) analizaron el uso de códigos HS y HTS en sistemas de clasificación aduanera, así como los desafíos asociados a la complejidad de la nomenclatura, la diversidad de descripciones de mercancías y la integración de tecnologías de información. El estudio señala que las tecnologías de información, el aprendizaje automático y los métodos de inteligencia artificial pueden contribuir a automatizar y optimizar los procedimientos de clasificación, mejorar la precisión y reducir los tiempos de procesamiento. Desde esta perspectiva, la clasificación arancelaria no se entiende únicamente como una tarea predictiva, sino como un proceso que requiere organización de información, actualización de bases de datos, calidad de datos y soporte tecnológico para mejorar la gestión del conocimiento aduanero.

2.1.2. Recuperación semántica para códigos HS

La recuperación semántica constituye una línea relevante para la clasificación arancelaria porque permite abordar la brecha entre el vocabulario comercial utilizado en las descripciones de mercancías y el vocabulario jurídico-técnico de la nomenclatura. A diferencia de los enfoques que producen una única predicción final, los métodos de recuperación permiten generar candidatos, ordenar alternativas y conservar evidencia documental asociada a cada recomendación.

Spichakova y Haav (2020) propusieron una medida combinada de similitud textual y similitud taxonómica para evaluar la corrección de códigos HS. El estudio incorpora la estructura jerárquica del Sistema Armonizado como parte del proceso de verificación, de modo que la similitud entre una descripción y un código no se evalúa solo por coincidencia textual, sino también por proximidad dentro de la taxonomía arancelaria. Este enfoque resulta relevante para sistemas que requieren considerar capítulos, partidas y subpartidas como niveles relacionados dentro de una estructura normativa.

Stassin et al. (2023) compararon modelos de similitud semántica mediante *embeddings* de oraciones frente a modelos supervisados para la predicción de códigos HS a nivel fino. Su trabajo se orienta a evaluar la capacidad de los modelos

semánticos para recuperar códigos correctos dentro de los primeros resultados, utilizando métricas de ranking como Top-k. Esta perspectiva es significativa porque desplaza la evaluación desde la predicción única hacia la recuperación de candidatos útiles para revisión, lo que resulta especialmente adecuado en contextos donde la decisión final requiere validación experta.

Sitisara et al. (2025) abordaron la búsqueda semántica de códigos HS mediante *word embeddings*. El estudio parte de las limitaciones de las búsquedas basadas en coincidencia exacta de términos, las cuales pueden fallar cuando las descripciones comerciales emplean vocabulario distinto al de la nomenclatura. La propuesta muestra que las representaciones semánticas pueden mejorar la recuperación de códigos relacionados, al aproximar expresiones comerciales y categorías arancelarias desde relaciones de significado y no únicamente desde coincidencias literales.

Hambarde y Proença (2023) revisaron avances recientes en recuperación de información, incluyendo modelos de primera etapa, modelos de segunda etapa, recuperación semántica, recuperación neural y reordenamiento. Esta revisión ofrece un marco metodológico para comprender los sistemas de recuperación como *pipelines* compuestos por etapas diferenciadas: identificación inicial de candidatos, ordenamiento, refinamiento y evaluación. Tal estructura es coherente con sistemas que combinan recuperación documental, ranking y generación de explicaciones basadas en evidencia.

Asudani et al. (2023) revisaron el uso de modelos de *word embeddings* y aprendizaje profundo en analítica textual. Su trabajo aporta fundamentos sobre la representación semántica de textos y la capacidad de los *embeddings* para capturar relaciones contextuales entre términos. En el dominio arancelario, estos enfoques permiten abordar descripciones breves y especializadas, en las que la recuperación de información relevante depende de reconocer similitudes semánticas entre expresiones comerciales y fragmentos normativos.

2.1.3. Explicabilidad en clasificación aduanera

La explicabilidad es un componente crítico en clasificación aduanera, debido a que la recomendación de un código arancelario debe poder revisarse, justificarse y contrastarse con evidencia normativa. En dominios regulados, la utilidad de un sistema de apoyo no se limita a sugerir una categoría probable; también depende de su capacidad para mostrar razones, fuentes y fragmentos documentales que permitan reconstruir el criterio utilizado.

Lee et al. (2021) desarrollaron un modelo basado en KoELECTRA para sugerir códigos HS a nivel de partida y subpartida, utilizando descripciones textuales de mercancías y recuperación de oraciones relevantes. El estudio integró clasificación y recuperación de evidencia textual, lo que representa una aproximación temprana hacia sistemas que no solo predicen códigos, sino que también identifican información documental relacionada con la recomendación. Esta relación entre predicción y evidencia es especialmente importante en clasificación arancelaria, donde la decisión requiere sustento técnico y normativo.

Lee et al. (2024) propusieron un modelo explicable de clasificación de productos para aduanas, orientado a sugerir códigos y generar razonamientos interpretables para funcionarios. El estudio constituye un antecedente central porque articula clasificación automática, explicación y apoyo a la decisión experta. Su enfoque reconoce que la clasificación aduanera es una tarea de decisión especializada, en la que los modelos deben ofrecer no solo resultados, sino también elementos interpretables que faciliten la revisión humana.

Grainger (2024) analizó el uso de tecnologías asistivas en clasificación arancelaria, considerando herramientas informativas, sistemas de apoyo y aplicaciones basadas en inteligencia artificial. Su estudio advierte que estas tecnologías deben evaluarse considerando la calidad de los datos, la comprensión de las características relevantes de las mercancías y los límites de la automatización. Esta perspectiva es relevante porque ubica la clasificación asistida dentro de un

marco de supervisión humana, responsabilidad técnica y prudencia en el uso de herramientas automatizadas.

Qi et al. (2025) propusieron un enfoque basado en conocimiento de atributos y redes de atención sobre grafos de conocimiento para predecir la exactitud de códigos HS asignados a mercancías de importación y exportación. El estudio desplaza el interés desde la asignación directa del código hacia la verificación de su consistencia mediante atributos relevantes y conocimiento estructurado. Esta aproximación contribuye a vincular clasificación arancelaria, representación de conocimiento y evaluación de exactitud, tres elementos necesarios para sistemas que buscan producir recomendaciones auditables.

Navasardyan (2024) evaluó un marco de clasificación HTS basado en GPT-3, con énfasis en *prompt engineering*, interpretabilidad y generalización. El trabajo se ubica dentro de la discusión reciente sobre el uso de modelos de lenguaje de gran tamaño en clasificación arancelaria. Su aporte consiste en explorar la capacidad de estos modelos para producir salidas interpretables sin necesidad de entrenamiento específico sobre grandes volúmenes de datos etiquetados, aunque su aplicación requiere control, verificación y criterios claros de evaluación.

Gholamian et al. (2024) estudiaron la clasificación de productos mediante modelos de lenguaje de gran tamaño bajo condiciones de descripciones incompletas o perturbadas. Su contribución se relaciona con la robustez de los modelos frente a entradas deficientes, aspecto especialmente relevante en contextos de comercio exterior, donde las descripciones de mercancías pueden ser breves, ambiguas, incompletas o contener variaciones terminológicas. Este antecedente refuerza la necesidad de analizar errores, sensibilidad a la calidad descriptiva y límites de confiabilidad en sistemas basados en LLM.

2.1.4. Documentación de datos/conocimiento

La documentación de datos y conocimiento constituye un eje necesario para investigaciones que emplean corpus textuales, descripciones de mercancías y salidas generadas por sistemas computacionales. En un sistema de recomendación auditable, la trazabilidad no depende únicamente del resultado final, sino de la posibilidad de reconstruir la procedencia de los documentos, los criterios de curación, la configuración del experimento y la relación entre evidencia recuperada y justificación generada.

Bender y Friedman (2018) propusieron los *data statements* como mecanismo para documentar *datasets* lingüísticos, describiendo aspectos como procedencia, características de los datos, población representada, condiciones de recolección y posibles sesgos. Su propuesta resulta aplicable a investigaciones que trabajan con datos textuales, porque permite explicitar el contexto de producción de los datos y evitar generalizaciones indebidas. En clasificación arancelaria, esta práctica se relaciona con la necesidad de documentar las descripciones de mercancías, sus fuentes y sus limitaciones.

Gebru et al. (2021) desarrollaron la propuesta de *datasheets for datasets*, orientada a documentar motivación, composición, proceso de recolección, usos recomendados, restricciones y mantenimiento de los conjuntos de datos. Esta perspectiva es relevante para la construcción de corpus normativos y conjuntos de evaluación, porque permite registrar no solo el contenido de los datos, sino también sus condiciones de uso, cobertura, limitaciones y riesgos. En sistemas de recuperación y generación aumentada por recuperación, dicha documentación resulta indispensable para asegurar trazabilidad y reproducibilidad.

Hambarde y Proença (2023), desde la recuperación de información, también aportan a la dimensión documental del proyecto al describir arquitecturas por etapas y componentes de búsqueda que requieren ser configurados, evaluados y reportados de manera diferenciada. En un *pipeline* de recuperación documental y reordenamiento, la documentación de cada etapa permite identificar qué corpus fue

usado, cómo se generaron los candidatos, qué parámetros intervinieron y cómo se produjo la salida final.

Grainger (2024) complementa esta dimensión al subrayar que las tecnologías asistivas en clasificación arancelaria dependen de la calidad de los datos, la comprensión del dominio y la evaluación cuidadosa. Esta perspectiva conecta la clasificación asistida con prácticas de gobernanza, documentación y control del conocimiento utilizado por el sistema. En consecuencia, la gestión documental no cumple una función secundaria, sino que constituye una condición para que las recomendaciones puedan ser revisadas, explicadas y auditadas.

En conjunto, los antecedentes muestran una evolución desde enfoques centrados en clasificación automática hacia aproximaciones más integrales que combinan recuperación semántica, explicabilidad, documentación y trazabilidad. Esta trayectoria respalda la necesidad de evaluar un piloto experimental offline que no se limite a medir desempeño predictivo, sino que incorpore la calidad de la evidencia documental, la verificabilidad de las explicaciones y la posibilidad de reconstruir el proceso de recomendación de subpartidas NANDINA.

2.2. Bases teóricas

2.2.1. Gestión del conocimiento e información

La gestión del conocimiento se entiende como el conjunto de procesos mediante los cuales una organización identifica, crea, almacena, recupera, transfiere y aplica conocimiento para mejorar la acción colectiva. Alavi y Leidner (2001) proponen que los sistemas de gestión del conocimiento no son simples repositorios documentales; su función es sostener procesos de creación, almacenamiento/recuperación, transferencia y aplicación de conocimiento. Esta definición es especialmente pertinente para el proyecto, porque la recomendación de

subpartidas NANDINA depende de la disponibilidad y uso adecuado de conocimiento normativo explícito.

La teoría de creación de conocimiento organizacional de Nonaka (1994) permite ubicar el problema en la relación entre conocimiento tácito y conocimiento explícito. En clasificación arancelaria, el conocimiento explícito se encuentra en nomenclaturas, reglas, notas y documentos legales; el conocimiento tácito aparece en la experiencia del especialista, en la capacidad de reconocer atributos relevantes y en la interpretación de casos límite. El enfoque experimental no reemplaza el conocimiento experto, pero busca convertir parte del sustento documental en evidencia recuperable, verificable y reutilizable.

La distinción entre datos, información y conocimiento también resulta útil. Rowley (2007) examina las representaciones de la jerarquía dato-información-conocimiento-sabiduría (DIKW) en textos de gestión de información y sistemas de información, identificando que la información suele definirse en términos de datos, y el conocimiento en términos de información, aunque existe escaso consenso sobre los procesos de transformación entre niveles. En el presente proyecto, una descripción de mercancía constituye un dato textual; su vinculación con fragmentos normativos produce información contextual, y la recomendación explicada y trazable configura una forma de conocimiento operativo para apoyar la revisión humana.

2.2.2. Conocimiento normativo arancelario y Sistema Armonizado

El Sistema Armonizado es una nomenclatura jerárquica internacional que organiza mercancías en capítulos, partidas y subpartidas. En la Comunidad Andina, la Nomenclatura Arancelaria Común de los Países Miembros de la Comunidad Andina (NANDINA) extiende dicha estructura a ocho dígitos. Desde la perspectiva del proyecto, la NANDINA se concibe como un dominio de conocimiento normativo: contiene categorías, relaciones jerárquicas, notas y criterios que deben ser representados de manera documentalmente trazable.

Grainger (2024) advierte que las tecnologías asistivas para clasificación arancelaria solo resultan útiles si comprenden características relevantes del HS, se apoyan en datos de calidad y son evaluadas con criterios adecuados. Lee et al. (2024) muestran que la clasificación puede beneficiarse de modelos que no solo sugieren códigos, sino que recuperan evidencia del manual HS. Estas contribuciones respaldan una premisa central: en dominios regulados, la calidad de una recomendación no se agota en su acierto; incluye la posibilidad de reconstruir por qué se sugirió una opción y qué evidencia la sustenta.

2.2.3. Recuperación de información para apoyo a decisiones

La recuperación de información se ocupa de identificar documentos o fragmentos relevantes respecto de una consulta. En este proyecto, la consulta corresponde a una descripción textual de mercancía y los documentos son fragmentos del corpus NANDINA y de documentos normativos relacionados. Los métodos clásicos, como BM25, recuperan por coincidencia ponderada de términos, mientras que los métodos densos buscan capturar similitud semántica mediante representaciones vectoriales. Karpukhin et al. (2020) muestran que un recuperador denso puede superar a BM25 en tareas de pregunta-respuesta cuando aprende representaciones de consultas y pasajes.

Para operar con colecciones vectoriales, los índices de vecinos aproximados permiten búsquedas eficientes. Malkov y Yashunin (2018) propusieron *Hierarchical Navigable Small World (HNSW)*, una estructura de grafos para búsqueda aproximada de vecinos cercanos que ofrece escalabilidad en espacios de alta dimensión. Por su parte, Khattab y Zaharia (2020) propusieron ColBERT, un modelo de recuperación con interacción tardía que preserva señales finas de similitud entre tokens y permite pre-computar representaciones documentales. Estos enfoques sustentan la evaluación de alternativas de recuperación para el corpus del estudio.

2.2.4. Modelos de lenguaje, RAG y explicación basada en evidencia

Los modelos de lenguaje de gran tamaño pueden generar respuestas fluidas y realizar razonamientos textuales, pero su uso en dominios normativos exige control documental. La generación aumentada por recuperación (RAG, por sus siglas en inglés) combina una etapa de búsqueda de evidencia con una etapa generativa, de modo que el modelo produzca una respuesta condicionada por fragmentos recuperados (Lewis et al., 2020). En el proyecto, RAG se interpreta como un mecanismo de gestión del conocimiento: selecciona evidencia del corpus, la utiliza para reordenar candidatos y exige que la salida incluya fragmentos verificables.

El enfoque LLM+RAG se justifica en tanto permite separar dos funciones: recuperar información pertinente y redactar una explicación estructurada. Sin embargo, la investigación no asumirá que una explicación generada es correcta por el solo hecho de estar redactada con coherencia. Por ello se evaluará la presencia de citas, la trazabilidad a fragmentos, la pertinencia de la evidencia y la concordancia entre evidencia y justificación. Esta decisión se alinea con trabajos de IA explicable para aduanas, donde la evidencia recuperada es parte del soporte para la decisión experta (Lee et al., 2024).

2.2.5. Documentación de datos, trazabilidad y reproducibilidad

La trazabilidad del corpus y de los casos de prueba es un componente central de la gestión del conocimiento. Bender y Friedman (2018) proponen declaraciones de datos para caracterizar *datasets* lingüísticos y evitar generalizaciones indebidas. Gebru et al. (2021) plantean las *datasheets for datasets* como práctica para documentar motivación, composición, proceso de recolección, usos recomendados y límites. En esta investigación, dichas prácticas se adaptarán a un corpus documental y a un conjunto de casos de evaluación, registrando fuente, versión, cobertura, criterios de exclusión, normalización y limitaciones.

La reproducibilidad se abordará mediante control de versiones, bitácoras de experimentos, registro de parámetros, conservación de *prompts*, semillas aleatorias cuando correspondan y almacenamiento de salidas estructuradas. Para ello, se utilizará un repositorio Git como mecanismo de trazabilidad del código, documentación metodológica, configuraciones experimentales y artefactos reproducibles del proyecto, excluyendo datos sensibles o no autorizados. Esta decisión no es un detalle técnico secundario: en una investigación de gestión del conocimiento, la validez del resultado depende de que otro investigador pueda reconstruir el proceso por el cual una recomendación fue producida y evaluada.

2.3. Marco conceptual o glosario

Tabla 1

Glosario operacional del proyecto.

Término	Definición operacional en el proyecto
Gestión del conocimiento	Proceso de identificación, organización, recuperación, transferencia y aplicación del conocimiento disponible en una organización o dominio especializado.
Gestión de información	Conjunto de prácticas para recolectar, estructurar, almacenar, recuperar y usar información de manera confiable y oportuna.
Sistema Armonizado (HS)	Nomenclatura internacional de clasificación de mercancías organizada jerárquicamente en capítulos, partidas y subpartidas.
NANDINA	Nomenclatura Arancelaria Común de los Países Miembros de la Comunidad Andina, expresada en ocho dígitos.
Top-k	Métrica o criterio de recomendación que considera si la respuesta correcta aparece dentro de los primeros k candidatos devueltos.
MRR	<i>Mean Reciprocal Rank</i> ; métrica que asigna mayor valor cuando la respuesta correcta aparece en posiciones superiores del ranking.
nDCG	<i>Normalized Discounted Cumulative Gain</i> ; métrica de ranking que pondera la relevancia según la posición del resultado.
LLM	<i>Large Language Model</i> ; modelo de lenguaje de gran tamaño entrenado para procesar y generar texto.

RAG	<i>Retrieval-Augmented Generation</i> ; arquitectura que combina recuperación de información con generación textual condicionada por evidencia recuperada.
Auditabilidad	Capacidad de revisar una recomendación, sus evidencias, parámetros y procedimiento de generación.
Verificabilidad	Capacidad de contrastar una afirmación o explicación contra un fragmento documental recuperado e identificable.
Trazabilidad	Capacidad de reconstruir la procedencia de los datos, documentos, fragmentos, configuraciones y salidas utilizadas en una recomendación.
HTS	<i>Harmonized Tariff Schedule</i> ; lista arancelaria derivada del Sistema Armonizado, utilizada por algunos países para clasificar mercancías y aplicar tarifas, restricciones, controles o registros estadísticos. En esta investigación se considera únicamente como referencia comparativa internacional, no como objeto de clasificación del piloto experimental.
Código HS	Código del Sistema Armonizado que identifica mercancías a nivel internacional. En el proyecto se emplea como referencia conceptual para comprender la estructura jerárquica sobre la cual se deriva la NANDINA.
Subpartida NANDINA	Código arancelario de ocho dígitos utilizado en la Nomenclatura Arancelaria Común de la Comunidad Andina. Constituye la etiqueta de referencia que el piloto busca recomendar.
Corpus documental	Conjunto organizado de documentos normativos y técnicos utilizados como base de conocimiento para recuperación documental, reordenamiento y generación de explicaciones.
Fragmento documental	Unidad mínima de texto recuperable dentro del corpus. Puede corresponder a una partida, subpartida, nota legal, regla o segmento normativo usado como evidencia.
Recuperación documental	Proceso mediante el cual el sistema identifica documentos o fragmentos relevantes del corpus a partir de una descripción textual de mercancía.
Recuperación semántica	Recuperación basada en similitud de significado entre la consulta y los documentos, no solo en coincidencia exacta de palabras.
<i>Baseline</i>	Configuración base de comparación del experimento. En el proyecto corresponde a la etapa inicial de recuperación documental sin reordenamiento LLM+RAG ni explicación estructurada.
Top-N	Conjunto inicial de N candidatos recuperados por la etapa base antes del reordenamiento. Se usa para evaluar cobertura de

	candidatos y alimentar el componente LLM+RAG.
Reordenamiento	Proceso de reorganizar los candidatos recuperados para ubicar en posiciones superiores aquellos más plausibles según la evidencia documental y el componente LLM+RAG.
Evidencia documental	Fragmento o conjunto de fragmentos recuperados del corpus que sustentan una recomendación o explicación.
Concordancia evidencia-justificación	Grado en que la explicación generada se encuentra efectivamente respaldada por los fragmentos documentales citados.
Piloto experimental offline	Evaluación controlada del enfoque propuesto sin despliegue operativo ni interacción con sistemas reales de decisión. Permite medir desempeño y auditabilidad bajo condiciones reproducibles.
Etiqueta de referencia	Subpartida NANDINA considerada correcta para una instancia de evaluación. Sirve como base para calcular métricas Top-k, MRR y nDCG.
<i>Prompt</i>	Instrucción estructurada suministrada al modelo de lenguaje para orientar el reordenamiento, la recomendación y la generación de explicación basada en evidencia.
<i>Embedding</i>	Representación vectorial de un texto que permite comparar similitud semántica entre descripciones de mercancías y fragmentos documentales.
BM25	Método clásico de recuperación de información basado en coincidencia ponderada de términos. Puede utilizarse como <i>baseline</i> de recuperación textual.
Índice vectorial	Estructura de búsqueda que almacena representaciones vectoriales de fragmentos documentales para permitir recuperación semántica eficiente.
Alucinación	Generación de afirmaciones no sustentadas por la evidencia documental recuperada. En el proyecto se controla mediante trazabilidad, verificabilidad y concordancia evidencia-justificación.

III. HIPÓTESIS Y VARIABLES

3.1. Hipótesis general

La aplicación de un piloto experimental offline de gestión de información documental, basado en recuperación documental y LLM+RAG, mejora la recomendación auditable de subpartidas NANDINA a partir de descripciones textuales de mercancías, en comparación con una recuperación base sin reordenamiento ni explicación estructurada, en términos de desempeño Top-k/ranking y calidad de explicación basada en evidencia.

3.2. Hipótesis específicas

- HE1.** La sistematización de enfoques de clasificación, recomendación y verificación de códigos HS permite fundamentar la selección del método base y los criterios de evaluación del piloto experimental.
- HE2.** La estructuración y documentación del corpus NANDINA mejora la trazabilidad del conocimiento utilizado por el piloto, al permitir identificar fuente, versión, fragmento y relación con cada recomendación.
- HE3.** La recuperación base permite incluir la subpartida correcta dentro de los candidatos Top-N en una proporción suficiente para habilitar el reordenamiento posterior.
- HE4.** El componente LLM+RAG mejora el desempeño Top-k y las métricas de ranking frente al ordenamiento inicial de la recuperación base.

HE5. Las explicaciones generadas por el componente LLM+RAG alcanzan niveles aceptables de verificabilidad, trazabilidad y concordancia evidencia-justificación según una rúbrica predefinida.

HE6. Los errores del piloto se concentran en descripciones ambiguas, categorías jerárquicamente próximas o mercancías con atributos insuficientemente expresados en la descripción de entrada.

3.3. Identificación de variables

La variable independiente es el enfoque experimental de gestión de información documental aplicado a la recomendación arancelaria. Esta variable se concreta en la curación y documentación del corpus, la configuración de recuperación documental y la incorporación del componente LLM+RAG para reordenamiento y explicación.

Las variables dependientes son dos: el desempeño de recomendación y la calidad de explicación auditable.

- El desempeño se observará mediante métricas Top-k y de ranking.
- La calidad de explicación se observará mediante indicadores de auditabilidad, verificabilidad, trazabilidad y concordancia entre evidencia y justificación.

Se consideran además variables de control relativas al corpus, conjunto de evaluación, granularidad documental, parámetros de recuperación, configuración del modelo y plantilla de salida.

3.4. Operacionalización de variables

Tabla 2

Operacionalización de variables

Variable	Dimensiones	Indicadores	Escala / criterio	Técnica / fuente
VI: Enfoque experimental de gestión de información documental	Curación y documentación del corpus	Existencia de metadatos; registro de fuente; versión; criterios de inclusión/exclusión; fragmentación documentada.	Cumple / no cumple; porcentaje de documentos con metadatos completos.	Análisis documental; ficha de corpus; bitácora de curación.
	Recuperación documental	Tipo de índice; granularidad; Top-N; longitud de contexto; parámetros de búsqueda.	Configuraciones experimentales predefinidas.	Registro de configuración; bitácora de ejecución.
	LLM+RAG para reordenamiento y explicación	Modelo/versión; temperatura; plantilla de prompt; formato de salida; uso de evidencia recuperada.	Configuraciones controladas por corrida.	Logs del experimento; salidas estructuradas.
VD1: Desempeño de recomendación	Cobertura de candidatos	Presencia del código correcto en Top-N.	Proporción de aciertos en Top-N.	Comparación contra etiqueta de referencia.
	Exactitud Top-k	Top-1, Top-3, Top-5.	Porcentaje de casos donde la subpartida correcta aparece dentro del k.	Evaluación offline del conjunto de prueba.
	Calidad de ranking	MRR; nDCG; posición media del código correcto.	Valor entre 0 y 1; mayor es mejor.	Cálculo estadístico sobre ranking por instancia.
VD2: Calidad de explicación auditable	Verificabilidad	La explicación cita fragmentos recuperados y estos existen en el corpus.	0: no verificable; 1: parcialmente verificable; 2: verificable.	Rúbrica de evaluación; revisión de evidencia.
	Trazabilidad	Identificación de documento, fragmento, versión y relación con el candidato recomendado.	0: ausente; 1: parcial; 2: completa.	Análisis de salidas estructuradas.
	Concordancia evidencia-justificación	La justificación no introduce afirmaciones no sustentadas por los fragmentos recuperados.	0: baja; 1: media; 2: alta.	Rúbrica cualitativa sobre muestra estratificada.
Variables de control	Condiciones experimentales	Corpus, casos, parámetros, modelo, prompt, entorno de ejecución.	Constantes o registradas por corrida.	Bitácora, repositorio y archivos de configuración.

3.5. Matriz de consistencia

Tabla 3

Matriz de consistencia del proyecto.

Problema	Objetivo	Hipótesis	Variables	Técnicas
PG: ¿En qué medida un piloto experimental offline de gestión de información documental con recuperación documental y LLM+RAG mejora la recomendación auditable de subpartidas NANDINA?	OG: Evaluar, mediante un piloto experimental offline, un enfoque de gestión de información documental para la recomendación auditable de subpartidas NANDINA.	HG: La aplicación de un piloto experimental offline de gestión de información documental, basado en recuperación documental y LLM+RAG, mejora la recomendación auditable de subpartidas NANDINA frente a una recuperación base sin reordenamiento ni explicación estructurada.	VI: Enfoque experimental de gestión de información documental. VD1: desempeño de recomendación. VD2: calidad de explicación.	Análisis documental; experimento offline; métricas Top-k, MRR, nDCG; rúbrica de explicación.
PE1: ¿Qué enfoques reporta la literatura para clasificación, recomendación y verificación de códigos HS?	OE1: Sistematizar enfoques reportados e identificar su aporte a la gestión de información documental normativa y a la explicación auditable.	HE1: La sistematización de enfoques de clasificación, recomendación y verificación de códigos HS permite fundamentar la selección del método base y los criterios de evaluación del piloto experimental.	VI: Enfoque experimental de gestión de información documental. Dimensión: fundamentación bibliográfica y selección metodológica.	Revisión bibliográfica; matriz de decisión.
PE2: ¿Cómo estructurar un corpus documental NANDINA para soportar recuperación, trazabilidad y explicación?	OE2: Construir o consolidar un corpus documental con curación, metadatos y versionamiento.	HE2: La estructuración del corpus mejora la trazabilidad del conocimiento utilizado.	VI: curación y documentación del corpus.	Análisis documental; ficha de corpus; control de versiones.

PE3: ¿En qué medida la recuperación base incluye la subpartida correcta dentro de Top-N?	OE3: Implementar y evaluar la recuperación base para generar candidatos Top-N.	HE3: La recuperación base incluye la subpartida correcta dentro de Top-N en proporción suficiente.	VD1: cobertura Top-N y ranking inicial.	Cálculo de cobertura Top-N, posición y ranking.
PE4: ¿En qué medida LLM+RAG mejora el reordenamiento y la recomendación final?	OE4/OE5: Implementar LLM+RAG y evaluar el pipeline completo con Top-k, MRR y nDCG.	HE4: LLM+RAG mejora métricas Top-k y ranking frente a recuperación base.	VD1: Top-1, Top-3, Top-5, MRR, nDCG.	Evaluación offline; pruebas pareadas cuando corresponda.
PE5: ¿En qué medida las explicaciones alcanzan calidad aceptable para auditoría?	OE6: Definir y medir indicadores de calidad de explicación para auditoría.	HE5: Las explicaciones alcanzan niveles aceptables de verificabilidad, trazabilidad y concordancia.	VD2: calidad de explicación auditable.	Rúbrica; indicadores automáticos; revisión cualitativa.
PE6: ¿Qué patrones de error y confusión se observan?	OE7: Analizar errores, confusiones jerárquicas y sensibilidad experimental.	HE6: Los errores se concentran en casos ambiguos, jerárquicamente próximos o con información insuficiente.	VD1 y VD2; variables de control.	Matrices de confusión; análisis por capítulo/partida/subpartida; análisis cualitativo.

IV. METODOLOGÍA

4.1. Tipo y diseño de investigación

La investigación será aplicada, tecnológica y de alcance evaluativo-comparativo.

- Es aplicada porque aborda un problema concreto de gestión de información documental normativa en clasificación arancelaria y busca generar conocimiento útil para un contexto práctico. Esta orientación es coherente con la definición de investigación aplicada del Manual de Frascati, que la entiende como una investigación original dirigida a adquirir nuevo conocimiento, pero orientada principalmente hacia un objetivo práctico específico (OECD, 2018).
- Asimismo, es tecnológica porque implementa y evalúa un artefacto computacional para organizar, recuperar y usar conocimiento documental, lo que se aproxima al desarrollo experimental entendido como trabajo sistemático orientado a producir o mejorar procesos, productos o servicios (OECD, 2018).
- Es evaluativo-comparativa porque mide el desempeño de una recuperación base frente a un pipeline LLM+RAG sobre las mismas instancias, utilizando métricas de ranking y criterios de calidad de explicación auditable. Esta comparación controlada permite estimar el aporte incremental del componente LLM+RAG, en coherencia con la experimentación en ingeniería de software orientada a evaluar métodos, técnicas o herramientas mediante medición y análisis sistemático (Wohlin et al., 2012).

El diseño será experimental offline por instancia. Cada descripción textual de mercancía será procesada bajo un pipeline controlado: primero, recuperación base para generar candidatos Top-N; segundo, reordenamiento y explicación mediante LLM+RAG; tercero, evaluación contra una etiqueta de referencia. Este diseño permite comparar el desempeño de una condición base con el desempeño de una intervención metodológica sobre las mismas instancias, lógica compatible con los diseños experimentales orientados a evaluar efectos bajo condiciones controladas (Shadish et al., 2002). Asimismo, al tratarse de un artefacto computacional evaluado mediante métricas, configuraciones y resultados reproducibles, el diseño se aproxima a los estudios experimentales en ingeniería de software, donde se evalúan métodos, técnicas o herramientas antes de su eventual adopción práctica (Wohlin et al., 2012). No se realizará despliegue operativo ni intervención sobre usuarios reales.

El enfoque será mixto, con predominancia cuantitativa. La dimensión cuantitativa se expresará en el cálculo de métricas de recuperación y ranking, como Top-k, MRR y nDCG, así como en la comparación entre la recuperación base y el pipeline final. La dimensión cualitativa se incorporará de manera acotada mediante el análisis de explicaciones, errores y concordancia evidencia-justificación a partir de una rúbrica. Esta combinación es pertinente porque el desempeño numérico permite medir la eficacia de la recomendación, mientras que la revisión cualitativa permite evaluar la calidad del sustento documental y la auditabilidad de las salidas generadas. En ese sentido, el enfoque se alinea con los diseños mixtos, en los que se integran datos cuantitativos y cualitativos para obtener una comprensión más completa del fenómeno evaluado (Creswell & Plano Clark, 2018; Hernández-Sampieri & Mendoza, 2018).

4.2. Unidad de análisis

La unidad principal de análisis será cada instancia compuesta por una descripción textual de mercancía y su subpartida NANDINA de referencia. Para la

evaluación de explicaciones, la unidad de análisis será cada salida estructurada generada por el piloto, compuesta por candidatos, puntajes, evidencia recuperada y justificación textual.

4.3. Población de estudio

La población de estudio estará conformada por las descripciones textuales de mercancías susceptibles de ser clasificadas en subpartidas NANDINA y por los documentos normativos que integran el conocimiento explícito requerido para orientar la clasificación. En términos operativos, se trabajará con dos poblaciones delimitadas: el corpus documental NANDINA y normativo asociado, y un conjunto de casos de evaluación con descripción y etiqueta de referencia.

El corpus documental estará compuesto por fuentes públicas de clasificación arancelaria, incluyendo la estructura NANDINA, reglas generales, notas y documentos complementarios disponibles para consulta pública. El conjunto de casos de evaluación se proyecta a partir de registros de Declaración Aduanera de Mercancías (DAM) de canal rojo con levante u otra fuente documentada que contenga descripción y subpartida de referencia. La delimitación exacta se documentará en la ficha de datos del estudio.

4.4. Tamaño de muestra

El tamaño de muestra proyectado para la evaluación offline será de aproximadamente 300 instancias con descripción textual y subpartida NANDINA de referencia, sujeto a disponibilidad y criterios de calidad. Esta cantidad resulta compatible con el alcance de un piloto experimental de maestría, permite calcular métricas Top-k y de ranking, y habilita análisis por grupos cuando exista suficiente representación por capítulo o familia arancelaria.

Para la evaluación cualitativa de explicaciones se seleccionará una submuestra estratificada aproximada de 50 casos, procurando incluir recomendaciones correctas e incorrectas, descripciones de diferente longitud y casos con cercanía jerárquica entre candidatos. La muestra cualitativa se utilizará para aplicar la rúbrica de auditabilidad, verificabilidad y concordancia evidencia-justificación.

4.5. Selección de muestra

La selección será no probabilística, intencional y controlada por criterios de inclusión. Se incluirán casos con descripción textual suficiente para el procesamiento, subpartida NANDINA de ocho dígitos y fuente trazable. Se excluirán registros duplicados, incompletos, sin etiqueta de referencia, con codificación inválida o cuya descripción no permita identificar una mercancía. Cuando la distribución lo permita, se aplicará estratificación por capítulo o grupos de capítulos para evitar una concentración excesiva en pocas familias arancelarias.

El procedimiento de selección se documentará mediante una ficha de *dataset* que indique fuente, fecha de obtención, número inicial de registros, reglas de limpieza, registros excluidos y número final de instancias. Esta documentación seguirá, en lo aplicable, las recomendaciones de documentación de *datasets* propuestas por Bender y Friedman (2018) y Gebru et al. (2021).

4.6. Técnicas de recolección de datos

Se utilizarán tres técnicas principales. Primero, análisis documental para recopilar, curar y estructurar el corpus normativo. Segundo, extracción y preparación de casos de evaluación con descripción y etiqueta de referencia. Tercero, registro experimental automatizado de configuraciones, rankings, fragmentos recuperados, *prompts*, respuestas del modelo y métricas resultantes.

La recolección documental seguirá estos pasos: identificación de fuentes públicas; descarga o registro de versión; conversión a texto cuando corresponda; segmentación en unidades recuperables; asignación de metadatos; validación básica de integridad; y almacenamiento en un repositorio controlado, con versionamiento mediante Git para código, documentación, configuraciones y salidas reproducibles, excluyendo datos sensibles o restringidos. La recolección experimental registrará cada corrida con identificador, fecha, versión del corpus, configuración de recuperación, modelo utilizado, parámetros, plantilla de *prompt* y archivo de salida.

4.7. Análisis e interpretación de la información

El análisis se realizará en cuatro niveles. En el primer nivel se evaluará la calidad de la materia prima: consistencia de codificación, duplicados, valores faltantes, longitud de descripciones, cobertura del corpus, granularidad de fragmentos y completitud de metadatos. En el segundo nivel se evaluará la recuperación base mediante cobertura Top-N, posición de la subpartida correcta y métricas de ranking.

Las configuraciones, scripts, bitácoras y salidas agregadas del experimento serán organizadas en un repositorio Git, a fin de permitir trazabilidad metodológica y reconstrucción del flujo experimental.

En el tercer nivel se evaluará el pipeline completo. Se calcularán Top-1, Top-3, Top-5, MRR y nDCG. Para contrastar la recuperación base frente al pipeline final se utilizarán pruebas pareadas cuando corresponda: prueba de McNemar para aciertos binarios Top-k y prueba de rangos con signo de Wilcoxon para métricas ordinales o continuas por instancia, siempre que las condiciones de aplicación sean adecuadas. Se reportarán intervalos de confianza mediante remuestreo bootstrap cuando sea pertinente.

En el cuarto nivel se evaluará la calidad de explicación. Se aplicarán indicadores automáticos sobre el total de casos, por ejemplo, presencia de cita, existencia de fragmento y vinculación con documento. Además, se aplicará una rúbrica cualitativa sobre la submuestra estratificada para evaluar pertinencia, verificabilidad, trazabilidad y concordancia evidencia-justificación. La interpretación de resultados distinguirá entre acierto predictivo y calidad del sustento documental, evitando concluir que una recomendación acertada es necesariamente auditable o que una explicación fluida es necesariamente válida.

Tabla 4

Fases metodológicas del proyecto

Fase	Actividad	Producto verificable
1. Curación documental	Identificación, limpieza, segmentación y metadato del corpus NANDINA y normativo.	Corpus versionado; ficha de corpus; reglas de segmentación.
2. Preparación de casos	Depuración de descripciones y etiquetas; validación de formato NANDINA; separación del conjunto de evaluación.	Dataset de evaluación; ficha de datos; criterios de exclusión.
3. Recuperación base	Indexación y generación de candidatos Top-N para cada descripción.	Ranking base; métricas de cobertura y ranking.
4. LLM+RAG	Reordenamiento de candidatos y generación de explicación con evidencia recuperada.	Salida estructurada por instancia; prompts; evidencias.
5. Evaluación	Cálculo de métricas, pruebas pareadas, rúbrica de explicación y análisis de errores.	Tablas de resultados; matrices de confusión; informe de errores.

V. PRESUPUESTO

El presupuesto es referencial y se formula para evaluar la viabilidad de una investigación de maestría ejecutada en modalidad offline, sin despliegue productivo. Se privilegia el uso de software libre, repositorios locales y servicios de cómputo acotados. Los montos podrán ajustarse cuando se defina la fuente final de datos, el modelo LLM y las condiciones de ejecución.

Tabla 5

Presupuesto referencial del proyecto.

Rubro	Descripción	Monto estimado (\$)
Bienes	Almacenamiento externo, respaldo de información y materiales menores.	300
Servicios	Uso eventual de API o cómputo en la nube para pruebas controladas de LLM+RAG.	900
Servicios	Impresión, encuadernación preliminar y revisión de formato.	350
Servicios	Acceso a conectividad, energía y contingencias operativas.	250
Remuneraciones	No aplica; investigación desarrollada por el tesista.	0
Contingencia	Margen para ajustes técnicos no previstos.	300
Total estimado		2,100

VI. CRONOGRAMA DE ACTIVIDADES

El cronograma se organiza en doce semanas, con actividades parcialmente solapadas por la naturaleza iterativa del piloto experimental. La revisión bibliográfica, la curación documental y la preparación del conjunto de evaluación se desarrollarán durante las primeras cinco semanas. Luego, entre las semanas cuatro y ocho, se diseñará el *baseline*, se implementará el componente LLM+RAG y se ejecutarán los experimentos. Finalmente, entre las semanas siete y doce, se realizará la evaluación cuantitativa y cualitativa, el análisis de errores, la redacción final y la revisión del documento.

Tabla 6

Cronograma de actividades.

Actividades	1	2	3	4	5	6	7	8	9	10	11	12	Producto esperado
Revisión bibliográfica y ajuste del marco teórico	X	X	X										Marco teórico y antecedentes sistematizados.
Curación y documentación del corpus		X	X	X									Corpus versionado y ficha documental.
Preparación del conjunto de evaluación			X	X	X								Dataset de evaluación depurado y documentado.
Diseño del baseline de recuperación				X	X	X							Índice base y protocolo de recuperación.
Implementación del componente LLM+RAG					X	X	X						Módulo de reordenamiento y salida estructurada.
Ejecución experimental y registro de resultados						X	X	X					Bitácoras, rankings y salidas por instancia.
Evaluación de métricas y pruebas estadísticas							X	X	X				Tablas de desempeño Top-k, MRR y nDCG.
Evaluación cualitativa de explicaciones								X	X				Rúbrica aplicada y matriz de evidencias.
Análisis de errores y discusión									X	X			Informe de errores y patrones de confusión.
Redacción final y revisión de estilo										X	X	X	Documento final de tesis revisado.

VII. REFERENCIAS BIBLIOGRÁFICAS

- Alavi, M., & Leidner, D. E. (2001). Review: Knowledge management and knowledge management systems: Conceptual foundations and research issues. *MIS Quarterly*, 25(1), 107-136. <https://doi.org/10.2307/3250961>
- Anggoro, A., Corcoran, P., De Widt, D., & Li, Y. (2025). Harmonized system code classification using supervised contrastive learning with Sentence BERT and multiple negative ranking loss. *Data Technologies and Applications*, 59(2), 279-301. <https://doi.org/10.1108/DTA-01-2024-0052>
- Asudani, D. S., Nagwani, N. K., & Singh, P. (2023). Impact of word embedding models on text analytics in deep learning environment: A review. *Artificial Intelligence Review*, 56, 10345–10425. <https://doi.org/10.1007/s10462-023-10419-1>
- Bender, E. M., & Friedman, B. (2018). Data statements for natural language processing: Toward mitigating system bias and enabling better science. *Transactions of the Association for Computational Linguistics*, 6, 587-604. https://doi.org/10.1162/tacl_a_00041
- Creswell, J. W., & Plano Clark, V. L. (2018). Designing and conducting mixed methods research (3rd ed.). *SAGE Publications*.
- Cuaya-Simbro, G., Hernandez-Vera, I., Ruiz, E., & Gutierrez-Fragoso, K. (2022). Automatic tariff classification system using deep learning. *International Journal of Advanced Computer Science and Applications*, 13(7). <https://doi.org/10.14569/IJACSA.2022.01307105>
- Ding, L., Fan, Z., & Chen, D. (2015). Auto-categorization of HS code using background net approach. *Procedia Computer Science*, 60, 1462-1471. <https://doi.org/10.1016/j.procs.2015.08.224>
- Geburu, T., Morgenstern, J., Vecchione, B., Vaughan, J. W., Wallach, H., Daumé III, H., & Crawford, K. (2021). Datasheets for datasets. *Communications of the ACM*, 64(12), 86-92. <https://doi.org/10.1145/3458723>
- Gholamian, S., Romani, G., Rudnikowicz, B., & Skylaki, S. (2024). LLM-based robust product classification in commerce and compliance [Preprint]. *arXiv*. <https://arxiv.org/abs/2408.05874>

- Grainger, A. (2024). Customs tariff classification and the use of assistive technologies. *World Customs Journal*, 18(1), 3-32.
<https://doi.org/10.55596/001c.116525>
- Hambarde, K. A., & Proença, H. (2023). Information retrieval: Recent advances and beyond. *IEEE Access*, 11, 76581–76604.
<https://doi.org/10.1109/ACCESS.2023.3295776>
- Hernández-Sampieri, R., & Mendoza Torres, C. P. (2018). Metodología de la investigación: Las rutas cuantitativa, cualitativa y mixta. *McGraw-Hill Education*.
- Karpukhin, V., Oguz, B., Min, S., Lewis, P., Wu, L., Edunov, S., Chen, D., & Yih, W. (2020). Dense passage retrieval for open-domain question answering. *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing*, 6769-6781. <https://doi.org/10.18653/v1/2020.emnlp-main.550>
- Khattab, O., & Zaharia, M. (2020). ColBERT: Efficient and effective passage search via contextualized late interaction over BERT. *Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval*, 39-48. <https://doi.org/10.1145/3397271.3401075>
- Krupa, S., & Kunanets, N. (2024). Analysis of the use of HS and HTS codes in customs classification systems: Challenges and opportunities of integration of IT technologies. *Information Systems and Networks*, 16, 237–250.
<https://doi.org/10.23939/sisn2024.16.237>
- Lee, E., Kim, S., Kim, S., Jung, S., Kim, H., & Cha, M. (2024). Explainable product classification for customs. *ACM Transactions on Intelligent Systems and Technology*, 15(2), Article 25. <https://doi.org/10.1145/3635158>
- Lee, E., Kim, S., Kim, S., Park, S., Cha, M., Jung, S., Yang, S., Choi, Y., Ji, S., Song, M., & Kim, H. (2021). Classification of goods using text descriptions with sentences retrieval [Preprint]. *arXiv*. <https://arxiv.org/abs/2111.01663>
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems*, 33, 9459–9474.
<https://proceedings.neurips.cc/paper/2020/hash/6b493230205f780e1bc26945df7481e5-Abstract.html>
- Liao, M., Huang, L., Zhang, J., Song, L., & Li, B. (2024). Enhanced HS code classification for import and export goods via multiscale attention and ERNIE-BiLSTM. *Applied Sciences*, 14(22), Article 10267.
<https://doi.org/10.3390/app142210267>

- Luppes, J. (2019). Classifying short text for the Harmonized System with convolutional neural networks [Master's thesis, Radboud University]. https://www.cs.ru.nl/masters-theses/2019/J_Luppes_Classifying_short_text_for_the_Harmonized_System_with_convolutional_neural_networks.pdf
- Malkov, Y. A., & Yashunin, D. A. (2018). Efficient and robust approximate nearest neighbor search using hierarchical navigable small world graphs. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 42(4), 824-836. <https://doi.org/10.1109/TPAMI.2018.2889473>
- Marra de Artiñano, I., Riottini Depetris, F., & Volpe Martincus, C. (2023). Automatic product classification in international trade: Machine learning and large language models (IDB Working Paper Series No. IDB-WP-01494). *Inter-American Development Bank*. <https://doi.org/10.18235/0004984>
- Navasardyan, Z. (2024). Interpretable and generalizable HTS code classification framework. *Economics, Finance and Accounting*, 1(13), 140. <https://doi.org/10.59503/29538009-2024.1.13-140>
- National Institute of Standards and Technology. (2023). Artificial intelligence risk management framework (AI RMF 1.0). *U.S. Department of Commerce*. <https://doi.org/10.6028/NIST.AI.100-1>
- Nonaka, I. (1994). A dynamic theory of organizational knowledge creation. *Organization Science*, 5(1), 14-37. <https://doi.org/10.1287/orsc.5.1.14>
- Organisation for Economic Co-operation and Development. (2018). Manual de Frascati 2015: Guía para la recopilación y presentación de información sobre la investigación y el desarrollo experimental. *OECD Publishing/FECYT*. <https://doi.org/10.1787/9789264310681-es>
- Qi, L., Zhang, Q., Lin, X., Zhang, J., & Liao, M. (2025). Attribute knowledge and KBGAT for predicting the accuracy of the harmonized system code for classifying import and export commodities. *Scientific Reports*, 15, Article 43504. <https://doi.org/10.1038/s41598-025-16580-7>
- Rowley, J. (2007). The wisdom hierarchy: Representations of the DIKW hierarchy. *Journal of Information Science*, 33(2), 163-180. <https://doi.org/10.1177/0165551506070706>
- Shadish, W. R., Cook, T. D., & Campbell, D. T. (2002). Experimental and quasi-experimental designs for generalized causal inference. Houghton Mifflin.
- Sitisara, S., Jinarat, S., Ngamsaard, W., & Suthikarnnarunai, N. (2025). Revolutionizing Harmonized System (HS) code search with semantic search and word embeddings: Empowering trade classifications. *Forum for Linguistic Studies*, 7(10), 356–371. <https://doi.org/10.30564/fls.v7i10.10822>

- Spichakova, M., & Haav, H.-M. (2020). Application of machine learning for assessment of HS code correctness. *Baltic Journal of Modern Computing*, 8(4), 698-718. <https://doi.org/10.22364/bjmc.2020.8.4.13>
- Stassin, S., Amel, O., Mahmoudi, S. A., & Siebert, X. (2023). Similarity versus supervision: Best approaches for HS code prediction. *En M. Verleysen (Ed.), ESANN 2023 proceedings: European Symposium on Artificial Neural Networks, Computational Intelligence and Machine Learning (pp. 175–180)*. [i6doc.com. https://doi.org/10.14428/esann/2023.ES2023-163](https://doi.org/10.14428/esann/2023.ES2023-163)
- Wohlin, C., Runeson, P., Höst, M., Ohlsson, M. C., Regnell, B., & Wesslén, A. (2012). *Experimentation in software engineering*. Springer. <https://doi.org/10.1007/978-3-642-29044-2>

VIII. ANEXOS

Anexo 1. Estructura preliminar de salida del piloto

La salida estructurada del piloto deberá registrar, como mínimo, los siguientes campos: identificador de caso, descripción original, candidatos recuperados, subpartida recomendada, puntaje, posición del código de referencia, fragmentos documentales utilizados, identificador de documento, versión del corpus, prompt aplicado, respuesta del modelo y observaciones de validación.

Tabla 7

Campos mínimos de salida estructurada.

Campo	Descripción
id_caso	Identificador único de la instancia evaluada.
descripcion	Descripción textual de la mercancía.
top_n_base	Lista de candidatos generados por la recuperación base.
top_k_final	Lista de candidatos reordenados por el componente LLM+RAG.
codigo_recomendado	Subpartida NANDINA recomendada en primera posición.
evidencias	Fragmentos recuperados con identificador de documento y posición.
justificacion	Explicación textual basada en evidencia documental.
configuracion	Parámetros de recuperación, modelo, prompt y fecha de corrida.

Anexo 2. Rúbrica preliminar de calidad de explicación auditable

Tabla 8

Rúbrica preliminar para explicación auditable

Criterio	0: insuficiente	1: parcial	2: adecuado
Verificabilidad	No cita evidencia o la evidencia no existe.	Cita evidencia, pero la relación es débil o incompleta.	Cita evidencia localizable y directamente revisable.
Trazabilidad	No identifica documento, versión o fragmento.	Identifica algunos elementos de procedencia.	Identifica documento, versión, fragmento y relación con la recomendación.
Pertinencia documental	La evidencia no corresponde al atributo relevante.	La evidencia es parcialmente pertinente.	La evidencia corresponde al atributo decisivo de clasificación.
Concordancia evidencia-justificación	La explicación introduce afirmaciones no sustentadas.	La explicación es mayormente consistente, con omisiones menores.	La explicación se limita a inferencias sustentadas por evidencia recuperada.
Claridad para auditoría	No permite reconstruir el criterio.	Permite reconstrucción parcial.	Permite revisar el criterio aplicado de forma clara y ordenada.

Anexo 3. Alcances y límites preliminares

El estudio se delimita a evaluación offline. No se evaluará interacción con usuarios institucionales, impacto operativo real, tiempos de atención en una entidad pública ni sustitución de la decisión experta. La recomendación producida por el piloto se interpretará únicamente como resultado experimental. La validez externa estará condicionada por la calidad, procedencia y cobertura del conjunto de casos utilizado.